

Los misteriosos flotantes

Recordemos lo que sabemos del entorno de Programación Científica Octave. Dijimos que es un entorno de trabajo **interpretado** para el **cálculo científico** y la **visualización de datos**. En consecuencia, Octave utiliza un **lenguaje de alto nivel** que permite concentrarnos en la **resolución de problemas** complejos.

Pero vimos que existe una limitación: la **resolución numérica** de problemas, a diferencia de la resolución matemática simbólica, introduce inevitablemente **errores de aproximación** (también llamados “errores de redondeo”).

Discutiremos ahora de **dónde** vienen estos errores. La respuesta es, esencialmente, de la **representación de los valores numéricos** en la arquitectura de los computadores.

El estándar IEEE 754

Vimos, a principios del semestre, que los **números no enteros** normalmente se codifican con el estándar **IEEE 754**, que permite representar este tipo de valores y algunos símbolos numéricos separándolos en tres componentes: **signo**, **mantisa** y **exponente**.

Para entenderlos, dijimos que los computadores usan una representación que se parece a la **notación científica**. Por ejemplo, el número 137.5625 puede representarse como el número $+1.375625 \times 10^2$. Pero esta expresión está en **base decimal**, y se cumple la siguiente relación de los dígitos, la posición que usan y potencias de 10 correspondientes:

$$\begin{aligned} 137.5625 &= 1 \cdot 100 + 3 \cdot 10 + 7 \cdot 1 + 5 \cdot 1/10 + 6 \cdot 1/100 + 2 \cdot 1/1.000 + 5 \cdot 1/10.000 \\ &= 1 \cdot 10^2 + 3 \cdot 10^1 + 7 \cdot 10^0 + 5 \cdot 10^{-1} + 6 \cdot 10^{-2} + 2 \cdot 10^{-3} + 5 \cdot 10^{-4} \\ &= (1 \cdot 10^0 + 3 \cdot 10^{-1} + 7 \cdot 10^{-2} + 5 \cdot 10^{-3} + 6 \cdot 10^{-4} + 2 \cdot 10^{-5} + 5 \cdot 10^{-6}) \cdot 10^2 \\ &= +1.375625 \times 10^2 \end{aligned}$$

Esta notación es cómoda para los seres humanos, pero no para los computadores, que usan una **base binaria** (**bits**). El computador entonces, tiene que representar el valor con unos y ceros. La clave está en representar el valor con potencias de 2, positivas o negativas.

$$\begin{aligned} 137.5625_{(10)} &= 1 \cdot 2^7 + 0 \cdot 2^6 + 0 \cdot 2^5 + 0 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 + 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 0 \cdot 2^{-3} + 1 \cdot 2^{-4} \\ &= (1 \cdot 2^0 + 0 \cdot 2^{-1} + 0 \cdot 2^{-2} + 0 \cdot 2^{-3} + 1 \cdot 2^{-4} + 0 \cdot 2^{-5} + 0 \cdot 2^{-6} + 1 \cdot 2^{-7} + 1 \cdot 2^{-8} + 0 \cdot 2^{-9} + 0 \cdot 2^{-10} + 1 \cdot 2^{-11}) \cdot 2^7 \\ &= +(1.00010011001)_{(2)} \times 2^7 \end{aligned}$$

Notemos entonces que los dígitos o **bits** antes del **punto decimal** (coma decimal en castellano) se asocian a **potencias con exponente positivo**, mientras que los dígitos o **bits** después del punto decimal, se asocian a **potencias con exponentes positivos**. El valor del exponente de cada potencia corresponde a la **distancia** que el dígito o **bit** tiene

En la precisión doble, **el primer bit** (63 en la figura) también se usa para representar **el signo**. Análogamente a la precisión simple, los siguientes **once bits** (62 al 52 en la figura) representan **el exponente** de la potencia común. También existe un desplazamiento de este valor, que en este caso es de **1.023**. Así, el exponente $7_{(10)}$ del ejemplo se convierte en $00000000111_{(2)} + 01111111111_{(2)} = 10000000110_{(2)}$. Los últimos **52 bits** (51 al 0 en la figura) se usan para la **mantisa**. También se omite el único *bit* a la izquierda del punto decimal. Luego se almacenan los otros bits (00010011001) y se completa con ceros. El valor no entero en base decimal se obtiene con la siguiente fórmula:

$$(-1)^{\text{signo}} \cdot \left(1 + \sum_{i=1}^{52} (b_{52-i} \cdot 2^{-i}) \right) \cdot 2^{(\text{exponente}-1023)}$$

Siguiendo nuestro ejemplo, nuevamente volvemos al valor original aplicando esta fórmula:
 $(-1)^0 \cdot (1 + 2^{-4} + 2^{-7} + 2^{-8} + 2^{-11}) \cdot 2^{(1030-1023)} = 1 \cdot 1.07470703125 \cdot 2^7 = 137.5625$.

Pregunta 1

Con tu grupo de trabajo, responde la primera pregunta de la actividad.

Para nuestro ejemplo, usar precisión simple o doble no hizo diferencia alguna. Pero esto no siempre es así. Ambas representaciones estándares entregan un **número limitado, predeterminado**, de *bits* para representar un valor. Pero, al igual que en la base decimal, existen valores que requieren un número infinito de cifras para escribirlos. Por ejemplo, $0,142857142857142847142857$ es sólo una aproximación del número racional $\frac{1}{7} = 0,142857\overline{}$. Análogamente, podemos representar una aproximación del número binario racional $0,00011\overline{}$:

Precisión simple	:	Binario: 00111101110011001100110011001101 Equivalente decimal: 0.100000001490116119384765625
Precisión doble	:	Binario: 0011111101110011001100110011001100110011001100110011001100110011010 Equivalente decimal: 0.100000000000000005551115123126

Estos son los **valores más cercanos** al racional decimal $\frac{1}{10}$ que podemos tener con el estándar IEEE 754. Aquí vemos una diferencia entre la precisión simple y la precisión doble: efectivamente la doble precisión representa un valor más cercano al 0.1 que queremos almacenar. Es una diferencia pequeña, pero puede hacerse importante en cálculos que requieren **iteraciones**. El Ejemplo 1 muestra la salida que entrega el programa `unDecimo.m` que compara los resultados de sumar 500.000 veces el valor $\frac{1}{10}$ usando precisión simple y precisión doble.

unDecimo.m

```
simple = single(0);  
doble = double(0);  
  
for i = 1:500000  
    simple = simple + single(1/10);  
    doble = doble + double(1/10);  
end  
  
format long;  
disp(simple)  
disp(doble)
```

Ejemplo 1

```
octave:1> source('c:/Desktop/unDecimo.m')  
50177.0976562500  
49999.9999995529  
octave:2>
```

El programa del Ejemplo 1 utiliza las funciones `single()` y `double()` para indicar **explícitamente** al intérprete de Octave qué representación usar para las variables y operaciones. También podemos ver la sintaxis para **construir iteraciones fijas**: comienzan con la palabra **for** y terminan con la palabra **end**; la variable **i** va tomando, en cada iteración, los valores del vector generado por el operador **:** que le aparece asignado. Al finalizar el ciclo, el programa solicita desplegar los valores, mediante la función `disp()`, con más decimales que lo que normalmente se despliegan.

Podemos ver que hay una diferencia notoria en el resultado final, y que con doble precisión nos acercamos bastante más al verdadero valor (50.000). El **impacto** que pueden tener estos **errores de aproximación** dependerá de la **aplicación** en el mundo real que estemos considerando.

Un ejemplo trágico ocurrió el 25 de febrero de 1991, durante la Primera Guerra del Golfo Pérsico. Las bases militares de EE.UU. estaban protegidas por el **sistema antimisiles Patriot**, que debía interceptar cualquier misil Scud que los iraquíes pudieran lanzarles.



Para evitar falsas alarmas, el radar del sistema Patriot debía detectar un objeto volador con las características de un Scud en **dos puntos distintos**. La posición del segundo punto, de confirmación, se calculaba a partir del primer lugar donde se detectaba el objeto, asumiendo que éste era un misil Scud. Si se le volvía a detectar en el punto de confirmación, el sistema Patriot lanzaba un misil para interceptarlo en pleno vuelo. Pero si no se le hallaba en ese punto, el sistema no lo consideraba un misil Scud y no entraba en acción.



Para calcular la posición de confirmación, se usaba el **tiempo del sistema**, que almacenaba el número de *ticks* de 0,1 segundos desde la puesta en marcha. Como vimos, en un computador, el valor 0,1 es aproximado, muy cerca, pero no exactamente 0,1. Al minuto del ataque, el sistema llevaba funcionando **100 horas**, o 3.600.000 *ticks* del reloj. La suma de estas pequeñas diferencias significó una desviación final de 0,3433 segundos. Un misil Scud recorre **687 metros en este tiempo**, por lo que el sistema Patriot no lo encontró una segunda vez. El misil ya había pasado, un tercio de segundo antes, y llegó a su destino matando a 28 soldados e hiriendo a otros 100.

Podemos ver que lo esencial que resulta que tengamos **conciencia** que para un computador el número 0,1 **no existe**. No importa lo que digan los manuales de programación, **los computadores no manejan números reales**.

Los flotantes

Técnicamente, los computadores manejan **números de punto flotante**, o simplemente **flotantes**, definidos por el estándar IEEE 754. Aunque muchos lenguajes de programación y paquetes de software especializados, entre ellos Octave, llamen a estos números “reales”, el conjunto de los flotantes (\mathbb{F}) es **distinto** al conjunto de los reales:

$$\mathbb{F} \neq \mathbb{R}$$

En consecuencia, **no todas las propiedades** que son válidas para \mathbb{R} son también válidas para \mathbb{F} . Octave hace preferencia por flotantes de doble precisión. En este caso, \mathbb{F} es (2, 53, -1022, 1023), es decir, los números en base 2 con mantisa de 53 *bits* y exponente variando entre -1.022 y 1.023. Eso significa que el **error relativo** entre un número real x y su reemplazante $fl(x) \in \mathbb{F}$ está dado por:

$$\frac{|x - fl(x)|}{|x|} \leq \frac{1}{2} 2^{\text{exponente}-52}$$

El valor $2^{\text{exponente}-52}$ es conocido como **eps** (por *machine epsilon*) y corresponde a la diferencia entre $fl(x)$ y el flotante más cercano que es mayor que $fl(x)$. A diferencia de \mathbb{R} , en donde entre un real y otro siempre hay infinitos valores intermedios, en \mathbb{F} no existe valor alguno entre $fl(x)$ y $fl(x) + \text{eps}$.

En Octave existe la constante predefinida **eps** que almacena la diferencia entre el valor uno y el siguiente flotante, mayor que uno, que puede representarse. Este valor corresponde a $\text{eps}(1) = 2^{-52} \cong 2,22045 \times 10^{-16}$. Podemos ver que este error relativo es bastante pequeño.

```
octave:1> eps
ans = 2.22044604925031e-016
octave:2>
```

```
octave:1> realmin, realmax
ans = 2.22507385850720e-308
ans = 1.79769313486232e+308
octave:2>
```

6

sorpresas.m

```
x = 1e-16 + 1 - 1e-16;  
y = 1e-16 - 1e-16 + 1;  
if(x == y)  
    disp('PRUEBA 1: IGUAL')  
else  
    disp('PRUEBA 1: DISTINTO')  
end  
  
fraccion = 58/40 - 1;  
fraccionEquivalente = 18/40;  
if(fraccion == fraccionEquivalente)  
    disp('PRUEBA 2: IGUAL')  
else  
    disp('PRUEBA 2: DISTINTO')  
end  
  
raizDos = sqrt(2);  
if(raizDos * raizDos ~= 2)  
    disp('PRUEBA 3: DISTINTO')  
else  
    disp('PRUEBA 3: IGUAL')  
end  
  
senoPi = sin(pi);  
if(senoPi ~= 0)  
    disp('PRUEBA 4: DISTINTO')  
else  
    disp('PRUEBA 4: IGUAL')  
end
```

Ejemplo 2

```
octave:1> source('c:/Desktop/sorpresa.m')  
PRUEBA 1: DISTINTO  
PRUEBA 2: DISTINTO  
PRUEBA 3: DISTINTO  
PRUEBA 4: DISTINTO  
octave:2>
```

En el programa `sorpresas.m` podemos ver la sintaxis para construir **bifurcaciones**, que en Octave toman la forma de construcciones `if-end`, `if-else-end` y `if-elseif-else-end`. También podemos observar dos de los **operadores de comparación**: `==` es el comparador de **igualdad** y `~=` es el comparador de **desigualdad** (“es distinto que”). También vemos las funciones nativas `sqrt()`, que devuelve la raíz cuadrada de un número, y `sin()` que corresponde a la función seno.

El Ejemplo 2 nos debe dejar una gran lección: tomar decisiones basándonos en la igualdad, o desigualdad, de flotantes puede llevarnos a **comportamientos inesperados**. Por ejemplo, un programa diseñado para que estudiantes de enseñanza media practiquen funciones trigonométricas, podría perfectamente preguntar por “el seno de π ” y discutir que la respuesta “0” es incorrecta porque no es igual a su cálculo de `sin(pi)`.

Incluso, a veces ni siquiera podemos confiar en los otros operadores de comparación. Por ejemplo, ¿cuántas iteraciones hace el programa de la derecha? Este programa muestro la sintaxis para construir ciclos `while-end` en Octave. Como en Python, el cuerpo del ciclo se ejecuta mientras la condición se cumpla.

```
suma = 0.0;  
while(suma < 1.0)  
    suma = suma + 1/10  
end
```

Pregunta 2

Ahora responde la segunda pregunta de la actividad, trabajando con tu equipo.

Incluso si evitamos usar flotantes en las condiciones de bifurcaciones y ciclos de nuestros programas, los flotantes nos pueden dar problemas con nuestros cálculos, debido principalmente porque los **errores de aproximación pueden acumularse**. De hecho, existe toda una sub-disciplina de la matemática, conocida como **análisis numérico** o **cálculo numérico**, dedicada al estudio de algoritmos robustos y estables para resolver problemas matemáticos numéricamente. En la mayoría de las ingenierías, este curso está más adelante en el currículum. Este curso será importantísimo para trabajar con operaciones complejas con números flotantes. Por ahora, un resultado del cálculo numérico que ejemplifica estos riesgos:

Archimedes propuso **aproximar el valor de π** calculando los perímetros de polígonos inscribiendo y circunscribiendo un círculo, comenzando con hexágonos, y duplicando el número de lados en cada iteración. Esta idea lleva naturalmente a la siguiente ecuación de recurrencia:

$$t_0 = \frac{1}{\sqrt{3}}, \quad t_{n+1} = \frac{\sqrt{(t_n)^2 + 1} - 1}{t_n}$$

Está demostrado que $3 \cdot 2^{n+1} \cdot t_n$ converge a π a medida que n aproxima infinito.

Pero este algoritmo es **inestable numéricamente**, es decir, cuando se usa en un computador, la fórmula comienza a converger a π por algunas iteraciones, pero luego los errores de aproximación de las operaciones con flotantes hacen que el resultado comience a alejarse.

Es más, esto se resuelve usando la siguiente ecuación recurrente, matemáticamente equivalente, pero **numéricamente estable**.

$$t_0 = \frac{1}{\sqrt{3}}, \quad t_{n+1} = \frac{t_n}{\sqrt{(t_n)^2 + 1} + 1}$$

Pregunta 3

Responde ahora, junto a tu grupo de trabajo, la tercera pregunta de la actividad.

Finalmente, debemos notar que en los ejemplos anteriores han aparecido **valores especiales**. Estos, y varios otros que no discutiremos, tienen una representación especial en el estándar IEEE 754, que no sigue la idea de la notación científica. Aunque no se trata de manera especial por los lenguajes de programación, el **valor cero** es especial porque \mathbb{F} contiene dos representaciones para él, ¡una positiva y otra negativa!

Vimos que está definido el valor **infinito** (Inf), positivo y negativo, que usualmente aparece al dividir por valores muy cercanos a cero. Otro valor especial es NaN (del inglés *not-a-number*) que aparece cuando una **operación no tiene sentido**. Por último, debemos mencionar el valor NA (del inglés *not-available*) que se usa para indicar que un **valor es desconocido**.

Por esta razón, Octave provee funciones nativas para verificar si alguno de nuestros flotantes a tomado un valor especial. Entre ellas: `isinf()`, `isnan()`, `isna()`, y la muy útil `isfinite()`, que retorna verdadero si un valor es finito, es decir no es Inf, ni NaN, ni NA.

Ejemplo 3

```
octave:1> 1/0, 1/-0
warning: division by zero
ans = Inf
warning: division by zero
ans = -Inf
octave:2> 0/0
warning: division by zero
ans = NaN
octave:3> x = [2 Inf 2 NaN 4 NA 4];
octave:4> mean(x)
ans = NA
octave:5> isfinite(x)
ans =

    1    0    1    0    1    0    1

octave:6> mean( x( isfinite(x) ) )
ans = 3
octave:6> NaN == NaN, NA == NA, Inf == Inf
ans = 0
ans = 0
ans = 1
octave:7> NaN - NaN == 0, NA - NA == 0, Inf - Inf == 0
ans = 0
ans = 0
ans = 0
octave:8>
```

En el Ejemplo 3 pueden verse algunos de los valores especiales. Primero notemos que debemos tener cuidado cuando operamos con ellos, puesto que los resultados no son siempre muy intuitivos. Por otro lado, podemos ver que las funciones para detectar valores especiales, y en general **la gran mayoría de las funciones** en Octave, **funcionan** no sólo para valores escalares, sino que también para **vectores y matrices**.